



# Rapport de projet Data Science

Luca Debeir, Simon Gayet, Alexandre Girbal, David Meier

Lien de l'application shiny : Shiny Data Science - Sujet 7

Lien du github : Github - Data Science

Lien des slides de la soutenance : Soutenance - Data Science



# Table des matières

Table des Figures	2
Introduction	3
Utilisation par rapport à la fréquence	4
Problématique	4
Données	4
Analyse	5
Hypothèse n°1:	5
Hypothèse n°2:	7
Hypothèse n°3:	8
Hypothèses n°4 et 5:	8
Conclusion du premier axe	13
Utilisation par rapport aux usages	14
Problématique	14
Données	14
Analyse	15
Hypothèse n°1:	15
Hypothèse n°2:	17
Hypothèse n°3:	18
Données	18
Analyse	18
Conclusion du second axe	20
Conclusion	21
Annexes	22
Annexe 1:	22
Annexe 2:	31
Annexe 3:	38
Annexe 4 : Server Shiny App	46
Annexe 5 : UI Shiny App	52



# **Table des Figures**

- Figure 1 : Diagramme sur R, répartition du nombre d'autos
- Figure 2 : Nombre de km parcourus en moto en fonction du km parcourus en voiture
- Figure 3 : Tableau de contingence de la fréquence en moto et en auto
- Figure 4 : Tableau de contingence de la fréquence en fonction du véhicule
- Figure 5 : Part de l'utilisation des véhicules par les utilisateurs
- Figure 6 : ACM par rapport à la fréquence, à la situation familiale et à l'assurance
- Figure 7 : Moyenne de km parcourus en moto en fonction de la situation familiale
- Figure 8 : Moyenne de km parcourus en auto en fonction de la situation familiale
- Figure 9 : Moyenne de km parcourus en moto et en auto en fonction de la situation maritale
- Figure 10 : Moyenne de km parcourus en auto en fonction de la situation maritale
- Figure 11 : Moyenne de km parcourus en moto en fonction de la situation maritale
- Figure 12 : Répartition des usages pour les motos et les automobiles
- Figure 13 : Répartition des usages pour les automobiles
- Figure 14 : Répartition des usages pour les motos
- Figure 15 : AFC sur les variables Véhicule et Usage
- Figure 16 : Tableau de contingence entre les variables fréquence automobile et usage
- Figure 17 : Tableau de contingence entre les variables fréquence moto et usage



## Introduction

Dans le cadre du projet data science, avons avons analysé les données fournis par la Mutuelle des Motards, une société proposant assurances et mutuelles aux conducteurs de deux-roues en France. Le sujet qui nous a été proposé est le suivant:

# <u>Sujet 7</u>: Comparer l'utilisation de la voiture et celle du 2-roues. Est-ce que les gros rouleurs en voiture sont aussi les gros rouleurs en 2-roues ?

Pour répondre à cette problématique nous disposons d'un questionnaire sur les motos et un autre sur les autos. Nous avons croisé les données pour ne garder que les utilisateurs ayant répondu à ces deux questionnaires pour pouvoir comparer l'utilisation de ces deux véhicules. Parmis ces individus 36.5 % possèdent une auto, c'est pourquoi il semblait intéressant de comparer l'utilisation de la voiture à celle des deux roues sur cet échantillon selon les 2 axes d'études suivants:

- L'utilisation par rapport à la fréquence
- L'utilisation par rapport aux usages

Afin de traiter nos axes, nous avons dû définir les gros rouleurs comme étant des individus parcourant plus de kilomètres qu'un kilométrage annuel arbitraire. Nous avons considéré que ce kilométrage serait la moyenne française des km parcourus tous véhicules confondus.

Ainsi nous savons avant de commencer un traitement des données approfondi que 18,45% des personnes ayant répondu aux questionnaires et ayant une voiture et une moto sont considérées comme des gros rouleurs en moto contre 33.11% qui sont considérées comme des gros rouleurs en voiture.



# 1. Utilisation par rapport à la fréquence

# **Problématique**

Les individus considérés comme des gros rouleurs seront les personnes roulant plus de **17 000 km/an**, ce qui est la moyenne française en 2015 d'après l'Argus.fr. Nous avons choisi une source externe pour établir ce que l'on considère comme un gros rouleur car l'échantillon des données n'est pas représentatif de la population étant donnée que le questionnaire est rempli sur la base du volontariat parmi les personnes inscrites à la mutuelle des motards. D'autre part les personnes roulant moins de 17 000 km/an seront à l'inverse considéré comme petits rouleurs.

Nous souhaitons alors comparer l'utilisation de la voiture et de la moto par rapport à cette séparation faite sur l'échantillon étudié.

Nous avons formulé cinq hypothèses pour traiter cet axe:

- <u>H1</u>: "Il y a une corrélation négative entre la fréquence d'utilisation de la moto et celle de la voiture."
- <u>H2</u>: "Les répondants ayant une voiture utilisent plus leur voiture que leur moto."
- H3: "Utilisation de la moto et de la voiture en corrélation le sexe."
- H4: "Les parents célibataires sont plus aptes à conduire une moto."
- <u>H5</u>: "Plus il y a d'enfant à charge plus c'est un gros rouleur en voiture."

Nous commencerons par sélectionner les données à analyser afin de répondre à nos hypothèses.

#### **Données**

Les données proviennent de réponse à des questionnaires envoyé par la mutuelle des motards à leurs abonnés dont un axé sur les motos et un autre sur les voitures. Nous croisons les données pour ne garder que les utilisateurs ayant répondu aux deux questionnaires. Nous traitons dans cette partie les km parcourus (c'est-à-dire la fréquence d'utilisation de chaque véhicule) en fonction de différents paramètres.

Le questionnaire des motos permet de renseigner jusqu'à 6 cylindrées et pour chacune d'entre elles de renseigner le nombre de km parcourus par an. Nous avons donc effectué une somme de ces kilométrages pour chaque individu afin d'obtenir une donnée "nombre total de km parcourus à moto". D'autre part le questionnaire des autos permet de renseigner le nombre de voitures mais demande le kilométrage seulement pour la première voiture la plus utilisée. Nous avons donc utilisé cette donnée en sachant que cela fausse probablement les résultats pour certains individus.

De plus grâce aux questionnaires nous connaissons certaines informations personnelles de chaque individu ( le nombre d'enfants, la situation familiale et maritale ...), qui sont utilisées pour répondre aux hypothèses émises précédemment.

Les données brutes sont disponibles à l'adresse suivante:

https://imag.umontpellier.fr/~toulemonde/filesIG4/ProjetDataScience/



# **Analyse**

#### Hypothèse n°1:

Afin de comparer les fréquences d'utilisation de ces véhicules, nous sommes partis de l'hypothèse qu'il y a une corrélation négative entre la fréquence d'utilisation de la moto et celle de la voiture.

Nous avons comme données, les km/an de chaque 2-roues possédé par les individus; nous les avons donc sommés pour obtenir le nombre de kilomètres parcouru en un an par une personne avec toutes ses motos confondus. Cependant, nous possédons le nombre de km/an seulement de la voiture principale de chaque individu. Or comme on peut le voir ci-dessous les répondant possèdent dans près de 55% des cas plus d'une seule voiture.

C'est pour cette raison que nos prochaines analyses concernant le nombre de kilomètres parcouru par an en voiture seront certainement à modérer.



Figure 1: Diagramme R, répartition du nombre d'autos

Nous avons donc réalisé un graphe comparant la fréquence d'utilisation de la voiture et de la moto avec en abscisse le nombre de kilomètres/an avec la voiture principale et en ordonnée le nombre de kilomètres/an toutes motos confondu.

Nous avons vu qu'il y avait certaines données incohérentes, c'est pourquoi nous avons réduit l'intervalle des km/an de 0 à 100 000.



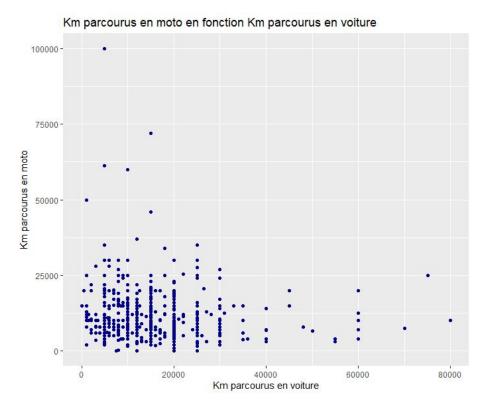


Figure 2 : Nombre de km parcourus en moto en fonction du km parcourus en voiture

On remarque la tendance suivante : si on roule beaucoup avec un véhicule on roule moins avec l'autre. On ne peut cependant pas déterminer qu'il y a une corrélation négative entre la fréquence d'utilisation de la moto et celle de la voiture.

Nous avons retraité les données correspondant aux kilomètres par an dans le but d'obtenir les variables qualitatives **rouleur moto** et **rouleur auto** définies précédemment.

Nous avons réalisé un test du chi-2 sur ces variables.

^	GrosRouleurAuto	PetitRouleurAuto
GrosRouleurMoto	19	44
PetitRouleurMoto	177	367

Figure 3 : Tableau de contingence de la fréquence en moto et en auto

> chisq.test(tabContingenceRouleur)

Pearson's Chi-squared test with Yates' continuity correction

data: tabContingenceRouleur
X-squared = 0.057523, df = 1, p-value = 0.8105



Le test ne nous permet pas de rejeter l'hypothèse d'indépendance car : la valeur de X-squared est inférieur à 3,84.

## Hypothèse n°2:

On se demande donc quel est le moyen de transport le plus utilisé parmi notre panel réduit. Afin de déterminer s'il existe un lien entre la fréquence d'utilisation et le véhicule, nous avons ci-dessous le tableau de contingence qui lie les données entre voiture et moto, à partir du nombre de kilomètres parcourus sur une année avec le véhicule principal.

*	Auto	Moto
Gros rouleur	196	63
Petit rouleur	411	544

Figure 4 : Tableau de contingence de la fréquence en fonction du véhicule

Le test du khi-2 sur ce tableau nous donne le résultat suivant :

#### > chisq.test(tabContingenceRouleur2)

```
Pearson's Chi-squared test with Yates' continuity correction
data: tabContingenceRouleur2
X-squared = 85.519, df = 1, p-value < 2.2e-16
```

Le test nous permet de rejeter l'hypothèse d'indépendance car : la valeur de X-squared > 3,84. Donc on a mis en évidence le lien entre la fréquence d'utilisation et les véhicules, mais nous ne pouvons pas en conclure plus avec cette analyse.



Nous pouvons voir sur le graphe ci-dessous qu'effectivement la voiture semble plus utilisée que la moto et ce malgré le fait que l'on connaisse la fréquence d'utilisation seulement de la voiture principale.

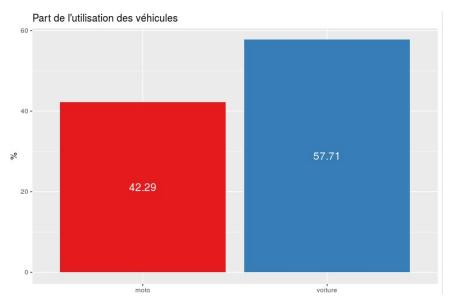


Figure 5 : Part de l'utilisation des véhicules par les utilisateurs

#### Hypothèse n°3:

Nous avons par la suite cherché à vérifier l'hypothèse suivante:

"L'utilisation de la moto et de la voiture est en corrélation avec le sexe."

Mais malheureusement il reste seulement une trentaine de femme dans notre jeu de données sur 607 individus. Ces chiffres nous semblant peu significatif nous avons décidé de ne pas traiter cette hypothèse.

## Hypothèses n°4 et 5:

Dans cette partie nous allons analyser les données de manière à répondre à ces hypothèses:

"Les parents célibataires sont plus aptes à conduire une moto qu'une voiture."

"Plus on a d'enfants à charge plus on est un gros rouleur en voiture."

Nous avons traité les données pour faire ressortir les deux variables qualitatives suivantes : situation familiale, avec ou sans enfant.

Nous nous sommes également questionné sur le lien entre le fait qu'un répondant soit assuré à la mutuelle des motards ou non.

Dans le but de voir les liens entre ces variables et nos variables précédemment définies : **rouleur moto** et **rouleur voiture** nous avons pensé à réaliser une ACM car c'est



la méthode adaptée aux tableaux de données où p variables qualitatives décrivent un ensemble d'individus.

Pour bien comprendre le résultat de l'ACM ci-dessous voici l'explication des variables:

Assure\_mutuelle\_1 : Les individus assurés à la mutuelle des motards.

Assure\_mutuelle\_0 : Les individus qui ne sont pas assurés à la mutuelle des motards.

en\_couple\_1: les individus qui sont en couples.

en\_couple\_0 : les individus célibataires.

avec\_enfant\_1 : les individus avec des enfants.

avec\_enfant\_0 : les individus sans enfants.

gros\_rouleur\_auto\_1 : Les individus qui roule plus de 17 000 Km/an avec leur voiture principale.

gros\_rouleur\_auto\_0 : Les individus qui roule moins de 17 000 Km/an avec leur voiture principale.

gros\_rouleur\_moto\_1 : Les individus qui roule plus de 17 000 Km/an avec toutes leurs motos confondus.

gros\_rouleur\_moto\_0 : Les individus qui roule moins de 17 000 Km/an avec toutes leurs motos confondus.

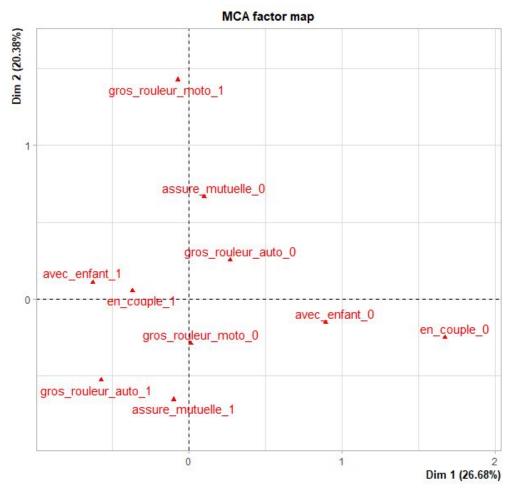


Figure 6 : ACM par rapport à la fréquence, à la situation familiale, à la situation maritale et à l'assurance



Nous voyons sur cette ACM que les gros rouleurs en autos semblent être assurés à la mutuelle des motards. Mais sans clusters évidents, nous n'avons pas su tirer d'informations claires et répondant à nos autres hypothèses.

On a donc réalisé des diagrammes que nous expliquerons par la suite pour vérifier nos deux hypothèses.

Tout d'abord nous avons cherché à savoir si une famille roulait plus suivant le nombre d'enfants à charge. Comme on peut le voir sur la figure 7 ci-dessous, cela semble être le cas pour les motos.

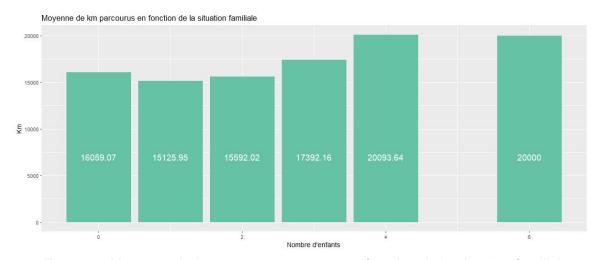


Figure 7 : Moyenne de km parcourus en moto en fonction de la situation familiale

Par contre contrairement à notre hypothèse on remarque que les familles n'utilisent pas plus la voiture lorsqu'ils ont plus d'enfants à charge. Cependant même si nous utilisons la moyenne des kilomètres parcourus pour analyser ces données, il faut cependant préciser que notre population est trop petite pour confirmer ou non nos hypothèses. En effet il y a une seule famille à 6 enfants sur 607 individus considérés.



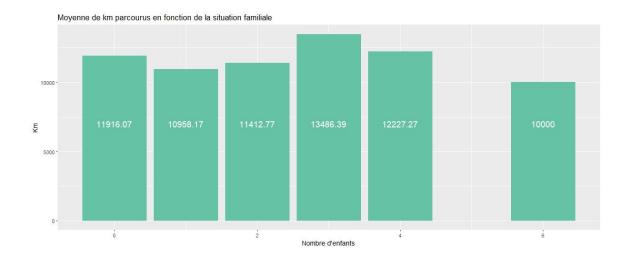


Figure 8 : Moyenne de km parcourus en auto en fonction de la situation familiale

On rappelle la seconde hypothèse que nous cherchons à vérifier dans cette partie : "Les parents célibataires sont plus aptes à conduire une moto qu'une voiture."

Pour y répondre nous avons réalisé trois diagrammes montrant la situation maritale respectivement le nombre de kilomètres parcourus en auto et à moto puis ceux parcourus en auto et enfin ceux parcourus à moto.

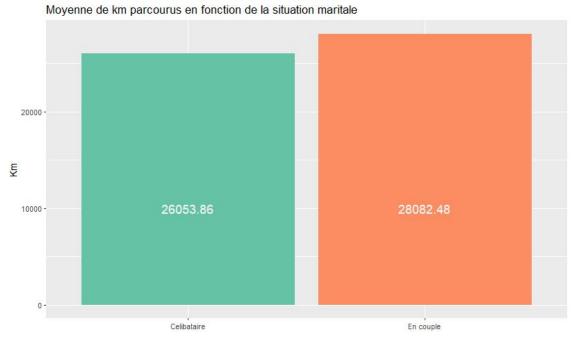


Figure 9 : Moyenne de km parcourus en moto et en auto en fonction de la situation maritale

Comme nous le voyons sur ce graphe, les individus en couple semblent rouler en moyenne plus que les individus célibataires.



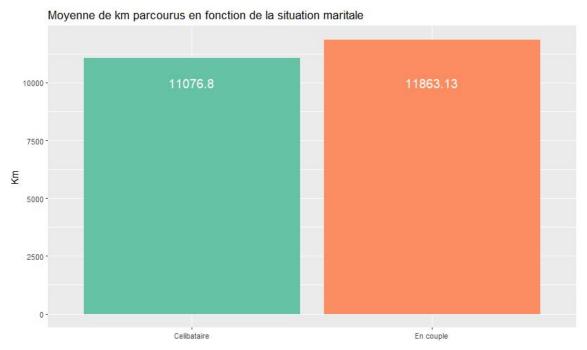


Figure 10 : Moyenne de km parcourus en auto en fonction de la situation maritale



Figure 11 : Moyenne de km parcourus en moto en fonction de la situation maritale



On constate à l'aide des figures 10 et 11 que les individus roulent environ le même nombre de kilomètres par an en auto contrairement au fait que la moto semble être plus utilisé par les couples ce qui contredit notre hypothèse à savoir : "Les parents célibataires sont plus aptes à conduire une moto qu'une voiture."

# Conclusion du premier axe

Dans cette partie nous avons cherché à comparer l'utilisation de l'auto et des 2-roues suivant la fréquence d'utilisation .

L'analyse faite pour répondre à notre première hypothèse ne nous permet pas de conclure que les gros rouleurs en voitures roulent moins à moto ni que les gros rouleurs à motos roulent moins en voitures.

Cependant il nous a permis de relever une certaine tendance. En effet, les très gros utilisateurs d'un type de véhicule avaient tendance à moins utiliser l'autre.

L'analyse de nos données nous a permis de nous rendre compte que les répondants roulent davantage en auto qu'en 2-roues ce qui nous a permis de valider notre deuxième hypothèse.

Ensuite par manque de données nous n'avons pu savoir s'il y avait une corrélation entre le sexe d'un individu et le nombre de kilomètres parcourus en auto et moto.

Pour finir, nous avons constaté que contrairement à ce que l'on pensait, les individus en couple roulaient plus à moto que ceux célibataires. De plus, bien que les familles semblent utiliser plus la moto lorsque leur nombre d'enfants à charge augmente, elle n'utilise pas plus l'auto pour autant.



# 2. Utilisation par rapport aux usages

# **Problématique**

Nous rappelons que le but de notre étude est de déterminer les facteurs qui influent sur la comparaison entre voitures et 2-roues au travers de la problématique suivante :

"Quels sont les différents facteurs qui amènent à la comparaison entre voiture et 2-roues? " Le facteur qui est étudié dans cette partie c'est l'usage des véhicules. Nous l'étudierons au travers de catégorie d'individus pour lesquelles nous avons formulé trois hypothèses :

- h1 "Les personnes qui ont des voitures et des motos ne les utilisent pas pour les mêmes usages."
- h2. "Les gros rouleurs sont ceux qui travaillent avec leurs voitures / motos."
- h3. "Etre un gros rouleur est indépendant de l'usage du véhicule."

Notre démarche sera d'abord de comprendre les usages pour l'ensemble des données sans catégoriser les individus. Puis nous analyserons plus finement pour comprendre la répartition des usages en fonction du type de véhicule et de la catégorie d'utilisateurs pour déterminer s'il y a corrélation. Cette analyse nous permettra de conclure sur les différentes hypothèses que nous avons formulées.

#### Données

Comme pour la partie précédente les données proviennent de réponse à des questionnaires envoyé par la mutuelle des motards à leurs abonnés. Un questionnaire correspond aux motos et un autre aux voitures. Nous avons croisé les données pour ne garder que les utilisateurs ayant répondu aux deux. La donnée importante de cette partie c'est l'usage qui est fait des véhicules. Le questionnaire des motos permet de renseigner jusqu'à 6 cylindrées et pour chacune d'entre elles de sélectionner un usage parmi : loisir, trajet domicile-travail, trajets professionnels. Le questionnaire des voitures permet de renseigner un véhicule et pour pour ce dernier de sélectionner un ou plusieurs usages parmi : sport ou autres loisirs, trajets domicile travail, trajets professionnels, les courses, sorties, vacances ou week-end. La manière de renseigner les usages et leurs types sont différents en fonction du type de véhicule, cela empêche de réaliser des comparaisons pertinentes. Pour palier à cela nous avons regroupé les usages : sport ou autres loisirs, sorties, vacances ou week-end ; en une catégorie loisir. Nous avons choisi de ne pas prendre en compte les course et magasin qui correspondait à une catégorie non proposer aux motos, cette catégorie reste pertinente et elle pourra être utilisée lors de la conclusion de l'analyse. Nous avons ainsi trois catégories identiques pour les usages des voitures et des motos. Nos individus sont catégorisés de la même manière que dans la partie précédente (gros rouleur, petit rouleur, situation familiale).



# **Analyse**

#### Hypothèse n°1:

Dans cette partie nous allons analyser les données de manière à répondre à cette hypothèse.

« Les personnes qui ont des voitures et des motos ne les utilisent pas pour les mêmes usages. »

Pour commencer on s'intéresse à l'usage que font les individus de leur véhicule de manière globale.



Figure 12 : Répartition des usages pour les motos et les automobiles

On constate que l'usage majoritaire correspond au loisir, l'utilisation domicile-travail est aussi beaucoup représentée. Par contre peu de personnes utilisent leur véhicule dans le cadre du travail.

On s'intéresse maintenant spécifiquement aux automobiles, nous avons remarqué dans le questionnaire que l'utilisateur pouvait sélectionner plusieurs usages différents, nous avons donc fait un graphe de l'usage global de l'automobile.

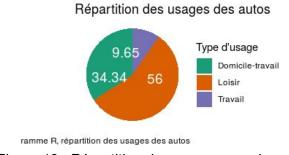


Figure 13 : Répartition des usages pour les automobiles

Pour les motos, nous avons remarqué que l'utilisateur pouvait mettre plusieurs motos différentes, mais que pour une moto, l'utilisateur avait un seul choix par véhicule. Nous avons donc fait un graphe sur l'usage principal de la moto. La catégorie « Personnel » correspond à la catégorie « Loisir ».



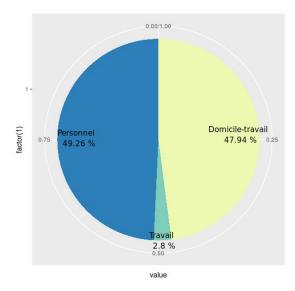


Figure 14 : Répartition des usages pour les motos

En comparant les 2 graphes on remarque déjà une petite différence entre les usages qui sont faits des voitures et des motos. Les motos sont moins utilisé dans le cadre du travail ce qui paraît logique, il est très rare de se déplacer à moto dans le cadre du travail. La moto est aussi favorisée pour les trajets domicile-travail une fois de plus cela peut s'expliquer de manière logique, on est en général tout seul pour aller au travail tandis que les loisirs peuvent être pratiqués à plusieurs.

Nous nous appuyons maintenant sur une Analyse Factorielle des Correspondances (AFC) pour confirmer ce que l'on observe en comparant grossièrement les données.

La première étape consiste à émettre l'hypothèse h0 : « Le type d'utilisation qui est faite par les individus des véhicules est indépendante du type de véhicule ». Le test du khi2 permet de rejeter cette hypothèse et de considérer que le type d'utilisation dépend du véhicule. Il est donc pertinent de réaliser une AFC.



#### La réalisation de l'AFC nous donne ce diagramme :

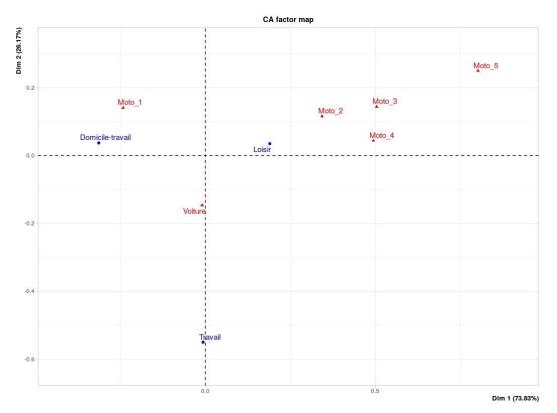


Figure 15 : AFC sur les variables Véhicule et Usage

Tout d'abord on remarque la représentation des axes est de 100%, nos données sont donc totalement représentées par ces axes. Trois groupes de véhicules se distinguent, la voiture, la moto principale puis les motos secondaires. L'axe 1 représente principalement les modalités Domicile-travaille et loisir, la modalité travail est représentée par l'axe 2. On constate que la voiture est bien privilégiée pour le travail, on remarque que la moto principale est plus destinée au trajet domicil travaille tandis que les motos secondaires correspondent plus aux loisirs.

On peut conclure que l'hypothèse est validée, l'usage des véhicules dépend en effet du type de véhicule. Cet usage dépend aussi de l'importance du véhicule. Il est important de nuancer le résultat en rappelant que pour la voiture les usagers avaient la possibilité de sélectionner plusieurs usages ce qui explique son positionnement central. Cela signifie que cette modalité est plus nuancée que les autres.



#### Hypothèse n°2:

Dans cette partie nous allons analyser les donnée de manière à répondre à cet hypothèse. Les gros rouleurs sont ceux qui travaillent avec leurs voitures / motos.

Après avoir récolté les données nécessaires, nous n'avons pas pu conclure sur cette hypothèse par manque de données. En effet, nous avons seulement 16 personnes sur 607 qui utilisent leur voiture pour les trajets professionnelles, et 17 personnes sur 607 qui utilisent leur moto.

Nous n'avons donc pas pu conclure sur cette hypothèse.

#### Hypothèse n°3:

Dans cette partie nous allons analyser les donnée de manière à répondre à cet hypothèse : Être un gros rouleur est indépendant de l'usage du véhicule.

#### Données

Les données importantes de cette partie sont : la fréquence d'utilisation et les usages des véhicules.

#### Analyse

Nous souhaitons comparer l'utilisation de la voiture et de la moto par rapport à la fréquence. Nous définissons la fréquence d'utilisation en fonction du nombre de kilomètre parcouru par an avec un véhicule. Et l'usage du véhicule en fonction du premier choix pour l'automobile, et le choix du premier véhicule pour la moto. Nous avons donc deux variables avec plusieurs modalités : la variable "Véhicule" avec "Gros rouleur" et "Petit rouleur" (définies précédent : gros rouleur si plus de 17000 km sur un an avec le véhicule), et la variable "Usage" avec :

- pour l'AFC avec les automobiles :
  - "Travail" pour les trajets professionnelles
  - "Domicile-travail" pour les trajets domicile-travail
  - "Personnel" pour les trajets personnels (sport, week-end, vacance..)
  - "Course" pour les trajets liés aux courses
- pour l'AFC avec les motos :
  - "Travail" pour les trajets professionnelles
  - "Domicile-travail" pour les trajets domicile-travail
  - "Personnel" pour les trajets personnels (sport, week-end, vacance..)



Dans le but de voir les liens entre ces variables, nous avons pensé à réaliser 2 AFC car c'est la méthode adaptée aux tableaux de données où 2 variables qualitatives décrivent un ensemble d'individus (une AFC pour chaque type de véhicule : Automobile et Moto). Pourquoi 2 analyses différentes selon le type de véhicule? Tout simplement parce que nous n'avons pas les mêmes données pour ceux-ci. Pour l'automobile, l'utilisateur peut sélectionner plusieurs usages différents. Nous avons sélectionné le premier dans la base de données, mais ceux-ci peut porter à confusion. Le résultat de cet AFC ne sera donc pas concluante à 100%. Contrairement à l'AFC sur la moto. En effet, pour celle-ci, l'utilisateur n'a qu'un choix possible, donc nous avons l'usage principale de la moto.

*	Personnel <sup>‡</sup>	DomicileTravail <sup>‡</sup>	Travail <sup>‡</sup>	Course <sup>‡</sup>
Gros rouleur Auto	110	61	11	14
Petit rouleur Auto	210	90	5	106

Figure 16 : Tableau de contingence entre les variables fréquence automobile et usage

Ci-dessus, nous avons le tableau de contingence pour l'AFC sur les automobiles. Celui-ci confirme aussi notre réponse à notre deuxième hypothèse (très peu de données pour bien analyser). Une fois ce tableau de fait, nous avons effectué un test du khi-deux afin de tester ces deux hypothèses :

H0 : le fait d'être un gros ou un petit rouleur est indépend de l'usage de l'automobile H1 : les deux variables sont dépendantes

#### > chisq.test(tabContingenceAuto)

```
Pearson's Chi-squared test

data: tabContingenceAuto

X-squared = 38.248, df = 3, p-value = 2.504e-08
```

Ici X-squared > 7,82 donc on rejette l'hypothèse d'indépendance. On a donc mis en évidence un lien entre les 2 variables.

^	Personnel	DomicileTravail	Travail
Gros rouleur Moto	18	39	6
Petit rouleur Moto	281	252	11

Figure 17 : Tableau de contingence entre les variables fréquence moto et usage

Ci-dessus, nous avons le tableau de contingence pour l'AFC sur les automobiles. Celui-ci confirme aussi notre réponse à notre deuxième hypothèse (très peu de données pour bien analyser). Une fois ce tableau de fait, nous avons effectué un test du khi-deux afin de tester ces deux hypothèses :

H0 : le fait d'être un gros ou un petit rouleur est indépend de l'usage de la moto

H1 : les deux variables sont dépendantes



#### > chisq.test(tabContingenceMoto)

```
Pearson's Chi-squared test

data: tabContingenceMoto

X-squared = 20.312, df = 2, p-value = 3.884e-05
```

Ici X-squared > 5,99 donc on rejette l'hypothèse d'indépendance. On a donc mis en évidence un lien entre les 2 variables.

⇒ Suite à nos deux tests du khi-deux, et donc à nos 2 AFC, nous avons pu conclure qu'il y a un lien entre la fréquence d'utilisation d'un véhicule et l'usage de ce véhicule.

#### Conclusion du second axe

Dans cette partie nous avons cherché à savoir si l'usage qui est fait des véhicules est un facteur de comparaison entre voitures et 2-roues. L'analyse liée à notre première hypothèse nous permet de conclure qu'il existe un lien entre le type de véhicule et l'usage qu'il en est fait. Ce lien peut permettre d'expliquer pourquoi certains utilisateurs vont privilégier un certain type de véhicule. Ce lien peut être caractérisé pas des contraintes professionnelles ou le besoin de se déplacer à plusieurs. L'analyse de la troisième hypothèse renseigne que le type d'usage qui est fait des véhicules est aussi lié au kilomètres que l'on parcourt avec. Il est assez évident qu'une personne utilisant son véhicule dans le cadre du travail réalisera plus de km qu'une personne qui ne l'utilise que dans un cadre privé et cela peu importe le type de véhicule.



# **Conclusion**

Au cours de l'analyse des données fournis par la Mutuelle des Motards nous avons comparé l'utilisation de la voiture et celle du 2-roues. Pour cela nous avons choisi deux axes d'études, la fréquence d'utilisation d'un véhicule et l'usage qu'on en fait. Notre but était de comprendre si le type de véhicule (2-roues et voiture) avait un impact sur nos axes. L'analyse des usages montre que ces derniers diffère en fonction du type de véhicule. On peut déduire de tout cela que lorsque les individus choisissent d'utiliser un certain type de véhicule ils prennent en compte l'usage qu'ils en auront. Le volume d'utilisation peut jouer un rôle mais nous n'avons pas réussi à le démontrer. Tout comme il ne semble pas y avoir de corrélation entre la manière d'utiliser les motos et la manière d'utiliser les voitures.



# **Annexes**

#### Annexe 1:

```
install.packages("readxl")
library("readxl")
bdd 2 roue <- read excel("Data/bdd 2 roue.xls")
View(bdd 2 roue)
bdd auto <- read excel("Data/bdd auto-modif.xlsx")</pre>
View(bdd auto)
#renommage des 2 premieres colonnes de la base 2-roue
colnames(bdd 2 roue)[colnames(bdd 2 roue)=="...1"] <- "Identifiant"</pre>
colnames(bdd 2 roue)[colnames(bdd 2 roue)=="...2"] <- "Date"</pre>
#creation de la base de donnees conjointes (avec les personnes utilisant auto et
bdd <- merge(bdd auto, bdd 2 roue, by="Identifiant")</pre>
#colnames(bdd moto 2019)[colnames(bdd moto 2019)=="IDENTIFIANT"] <- "Identifiant"
install.packages("ggplot2")
install.packages("dplyr")
library(ggplot2)
library(dplyr)
```



```
#---- Usage table ----#
de km associé
usage <- bdd %>%
                                                                             [1]",
usageVoiture2="Q15 [2]",
                 usageVoiture6="Q15 [6]", usagev1="Usage 1", kmv1="Nb km 1",
usagev2="...54",
        usagev5="...88", kmv5="...90")
usages <- bdd %>%
usages[is.na(usages)] <- 0
#fonctions pour transformer les donnees numériques en texte
to readable auto <- function(code){
to readable auto vector <- Vectorize(to readable auto, vectorize.args = "code")
to readable moto <- function(code){
```



```
to readable moto vector <- Vectorize(to readable moto, vectorize.args = "code")
usages <- usages %>%
mutate(Usage_moto = to_readable_moto_vector(usage_moto1))
nbUsager <- nrow(bdd)
usageMotoPersonnelGlobal <- sum(usages['Usage moto'] == 'Personnel')
usageMotoDomicileTravailGlobal <- sum(usages['Usage moto'] == 'Domicile-travail')
usageMotoTravailGlobal <- sum(usages['Usage moto'] == 'Travail')</pre>
#Camembert usage principal moto
usagePrincipalMoto <- data.frame(
                              c(round((usageMotoDomicileTravailGlobal/nbUsager),4),
round((usageMotoTravailGlobal/nbUsager),4),
library(extrafont)
loadfonts(device="win")
usagePrincipalMoto$group <-
rev(usagePrincipalMoto$group))
ggplot(data = usagePrincipalMoto, mapping = aes(x = factor(1), y = value, fill =
group)) +
```



```
geom bar(width=1, stat = "identity") +
 coord polar(theta = "y") +
 scale fill brewer(type = "seq", direction = -1, palette= "YlGnBu", guide = F) +
 geom_text(aes(x = c(1.3, 1.5, 1.3),
               label=paste(group,"\n", value*100, "%")), family = "Consolas")
usageAutoPersonnelGlobal <- sum(usages['Usage auto'] == 'Personnel')
usageAutoDomicileTravailGlobal <- sum(usages['Usage auto'] == 'Domicile-travail')
usageAutoTravailGlobal <- sum(usages['Usage auto'] == 'Travail')
usageAutoCourseGlobal <- sum(usages['Usage auto'] == 'Courses')
usagePrincipalAuto <- data.frame(
                                    c(round((usageAutoPersonnelGlobal/nbUsager),4),
round((usageAutoDomicileTravailGlobal/nbUsager),4),
                                        round((usageAutoTravailGlobal/nbUsager),4),
round((usageAutoCourseGlobal/nbUsager),4))
library(extrafont)
loadfonts(device="win")
usagePrincipalAuto$group <-
                                   factor(usagePrincipalAuto$group,
rev(usagePrincipalAuto$group))
ggplot(data = usagePrincipalAuto, mapping = aes(x = factor(1), y = value, fill =
group)) +
 coord polar(theta = "y") +
 scale fill brewer(type = "seq", direction = -1, palette= "YlGnBu", guide = F) +
 geom_text(aes(x = c(1.3, 1.5, 1.3, 1.3),
               y = value/2 + c(0, cumsum(value)[-length(value)]),
               label=paste(group, "\n", value*100, "%")), family = "Consolas")
usageGlobalAutoPerso
round(((usageVoiture[1,][2]+usageVoiture[5,][2]+usageVoiture[6,][2])/usageVoiture[7
][2]),4)
```



```
usageGlobalAutoDT <- round((usageVoiture[2,][2]/usageVoiture[7,][2]),4)
usageGlobalAutoT <- round((usageVoiture[3,][2]/usageVoiture[7,][2]),4)
usageGlobalAutoC <- round((usageVoiture[4,][2]/usageVoiture[7,][2]),4)
usageGlobalAuto <- data.frame(
 value = c(usageGlobalAutoPerso[1,],
library(extrafont)
loadfonts(device="win")
usageGlobalAuto$group <-
                                 factor(usageGlobalAuto$group,
                                                                      levels
rev(usageGlobalAuto$group))
ggplot(data = usageGlobalAuto, mapping = aes(x = factor(1), y = value, fill =
group) +
 geom bar(width=1, stat = "identity") +
 scale fill brewer(type = "seq", direction = -1, palette= "YlGnBu", guide = F) +
              y = value/2 + c(0, cumsum(value)[-length(value)]),
              label=paste(group,"\n",value*100, "%")), family = "Consolas")
grosRouleurAuto <- 0
grosRouleurMoto <- 0
petitRouleurAuto <- 0
petitRouleurMoto <- 0
repartitionRouleur <- function(code) {
```



```
for (i in (bdd$`Q17 [1]`))
 if (repartitionRouleur(strtoi(i)) == 1) {
  petitRouleurAuto <- petitRouleurAuto + 1</pre>
for (i in (bdd$`Nb km 1`))
 if (repartitionRouleur(strtoi(i)) == 1) {
   petitRouleurMoto <- petitRouleurMoto + 1</pre>
usageAutoPersonnelGrosRouleur <- 0
usageAutoTravailGrosRouleur <- 0
usageAutoDTGrosRouleur <- 0
usageAutoCourseGrosRouleur <- 0
usageAutoPersonnelPetitRouleur <- 0
usageAutoTravailPetitRouleur <- 0
usageAutoDTPetitRouleur <- 0
usageAutoCoursePetitRouleur <- 0
usageMotoPersonnelGrosRouleur <- 0
usageMotoTravailGrosRouleur <- 0
usageMotoDTGrosRouleur <- 0
usageMotoPersonnelPetitRouleur <- 0
usageMotoTravailPetitRouleur <- 0
usageMotoDTPetitRouleur <- 0
```



```
for (i in 1:nrow(bdd))
 if (bdd$`Q15 [1]`[i] == 1 || bdd$`Q15 [1]`[i] == 5 || bdd$`Q15 [1]`[i] == 6) {
  if (repartitionRouleur(strtoi(bdd$`Q17 [1]`[i])) == 1) {
     usageAutoPersonnelGrosRouleur <- usageAutoPersonnelGrosRouleur + 1
 } else if (bdd$`Q15 [1]`[i] == 2) {
   if (repartitionRouleur(strtoi(bdd$`Q17 [1]`[i])) == 1) {
     usageAutoDTPetitRouleur <- usageAutoDTPetitRouleur + 1</pre>
 } else if (bdd$`Q15 [1]`[i] == 3) {
   if (repartitionRouleur(strtoi(bdd$`Q17 [1]`[i])) == 1) {
     usageAutoTravailGrosRouleur <- usageAutoTravailGrosRouleur + 1</pre>
  if (repartitionRouleur(strtoi(bdd$`Q17 [1]`[i])) == 1) {
     usageAutoCourseGrosRouleur <- usageAutoCourseGrosRouleur + 1</pre>
     usageAutoCoursePetitRouleur <- usageAutoCoursePetitRouleur + 1
 for (i in 1:nrow(bdd))
   if (repartitionRouleur(strtoi(bdd$`Nb km 1`[i])) == 1) {
     usageMotoPersonnelGrosRouleur <- usageMotoPersonnelGrosRouleur + 1
     usageMotoDTPetitRouleur <- usageMotoDTPetitRouleur + 1</pre>
```



```
usageMotoTravailGrosRouleur <- usageMotoTravailGrosRouleur + 1</pre>
     usageMotoTravailPetitRouleur <- usageMotoTravailPetitRouleur + 1</pre>
tabContingenceAuto <- data.frame(
 Personnel=c(usageAutoPersonnelGrosRouleur,
             usageAutoPersonnelPetitRouleur),
                   usageAutoDTPetitRouleur),
resCA<-CA(tabContingenceAuto)
tabContingenceMoto <- data.frame(
 Personnel=c(usageMotoPersonnelGrosRouleur,
             usageMotoPersonnelPetitRouleur),
                   usageMotoDTPetitRouleur),
 Travail=c (usageMotoTravailGrosRouleur,
           usageMotoTravailPetitRouleur),
resCA<-CA(tabContingenceMoto)
GrosRouleurAutoetMoto <- 0
GrosRouleurAutoetPetitRouleurMoto <- 0
```



```
GrosRouleurMotoetPetitRouleurAuto <- 0
PetitRouleurAutoetMoto <- 0
for (i in 1:nrow(bdd))
 if (repartitionRouleur(strtoi(bdd$`Nb km 1`[i])) == 1) {
  if (repartitionRouleur(strtoi(bdd$`Q17 [1]`[i])) == 1) {
     GrosRouleurMotoetPetitRouleurAuto <- GrosRouleurMotoetPetitRouleurAuto + 1
 } else if (repartitionRouleur(strtoi(bdd$`Nb km 1`[i])) == 0) {
  if (repartitionRouleur(strtoi(bdd$`Q17 [1]`[i])) == 1) {
     GrosRouleurAutoetPetitRouleurMoto <- GrosRouleurAutoetPetitRouleurMoto + 1</pre>
     PetitRouleurAutoetMoto <- PetitRouleurAutoetMoto + 1</pre>
tabContingenceRouleur2 <- data.frame(
 Auto=c(grosRouleurAuto,petitRouleurAuto),
 Moto=c(grosRouleurMoto,petitRouleurMoto),
resAFCRouleur2 <- CA(tabContingenceRouleur2)
```



#### Annexe 2:

```
intro <- bdd %>%
 select(Identifiant, Q1="Q1 [1]") %>%
 arrange(Q1) %>%
group by(Q1) %>%
View(intro)
intro2 <- intro %>%
arrange(desc(Q1)) %>%
 mutate(prop = round(Nombre de personnes / sum(intro$Nombre de personnes) *100,2))
응>응
 mutate(ypos = cumsum(prop) - 0.5*prop )
diag_intro <- ggplot(intro2, aes(x = "", y = prop, fill = factor(Q1))) +</pre>
 geom bar(width = 1, stat = "identity") +
     x=NULL,
     title="R*partition du nombre d'autos",
     caption="Figure 1: Diagramme R, r♦partition du nombre d'autos") +
 geom text(aes(y = ypos, label = prop), color = "white", size=5,check overlap =
 scale fill brewer(palette="Set1") +
 coord_polar("y", start=0)
```



```
gros rouleurs <- bdd %>%
kmAuto="Q17 [1]", Assure Mutuelle = "Assur� Mutuelle", Nombre personnes foyer =
#class(gros rouleurs$moto1)
#On doit changer le type pour pouvoir sommer
gros rouleurs$moto1 <- as.numeric(as.character(gros rouleurs$moto1))</pre>
gros rouleurs$moto2 <- as.numeric(as.character(gros rouleurs$moto2))
gros_rouleurs$moto3 <- as.numeric(as.character(gros_rouleurs$moto3))</pre>
gros rouleurs$moto4 <- as.numeric(as.character(gros rouleurs$moto4))</pre>
gros rouleurs[is.na(gros rouleurs)] <- 0</pre>
gr sum <- gros rouleurs %>%
arrange(desc(kmMoto))
View(gr sum)
gr_sum_total <- gr_sum %>%
mutate(kmTotaux = kmMoto + kmAuto)
moyenne km an echantillon <- mean(gr sum total$kmTotaux) #27718.2 km
moyenne km an <- 17000
isGrosRouleur moto <- function(km){
 if (km <= moyenne km an)</pre>
 if (km > moyenne_km_an)
isGrosRouleur moto vector <- Vectorize(isGrosRouleur moto, vectorize.args = "km")
isGrosRouleur auto <- function(km){
 if (km <= moyenne km an)</pre>
```



```
if (km > moyenne km an)
isGrosRouleur_auto_vector <- Vectorize(isGrosRouleur_auto, vectorize.args = "km")</pre>
isAssure <- function(num){
isAssure vector <- Vectorize(isAssure, vectorize.args = "num")</pre>
situation_familiale <- function(num){
situation familiale vector <- Vectorize(situation familiale, vectorize.args
is en couple <- function(situation){
is_en_couple_vector <- Vectorize(is en couple, vectorize.args = "situation")
```



```
hasEnfants <- function(situation){
hasEnfants vector <- Vectorize(hasEnfants, vectorize.args = "situation")
type rouleur <- gr sum total %>%
 mutate(gros rouleur moto = isGrosRouleur moto vector(kmMoto)) %>%
 mutate(en_couple = is_en_couple_vector(situation_familiale)) %>%
select(Identifiant,gros rouleur moto,gros rouleur auto,assure mutuelle,en couple,av
ec enfant,kmTotaux,kmAuto,kmMoto)
View(type rouleur)
situation couple <- type rouleur %>%
  group by(en couple) %>%
  summarise(moy km moto = round(mean(kmAuto, na.rm=TRUE),2),
            moy km auto = round(mean(kmMoto),2),
View(situation couple)
kmEtudie <- situation_couple$moy_km_auto
kmEtudie <- situation couple$moy km moto
ggplot(data=situation couple, aes string(x="en couple", y=kmEtudie,
                                                                           fill
```



```
geom bar(stat="identity") +
 scale_fill_brewer(palette="Set1") +
 labs(fill="situation",
     y="Km",
 geom text(aes string(y = kmEtudie / 2, label = kmEtudie ), color = "white",
size=5) +
 theme(legend.position="none")
install.packages(c("FactoMineR", "factoextra"))
install.packages("questionr")
library("FactoMineR")
library("factoextra")
library("questionr")
type rouleur2 <- type rouleur
str(type rouleur2)
for(i in 2:6){
 type rouleur2[,i]<-as.factor(type rouleur2[,i])</pre>
res.mca <- MCA(type rouleur2[,2:6])
plot(res.mca,invisible=c("ind"))
tab situation familiale moto
table(type rouleur$situation familiale,type rouleur$gros rouleur moto,type rouleur$
gros rouleur auto)
chisq <- chisq.test(tab situation familiale moto)</pre>
tab situation familiale moto <- rprop(tab situation familiale moto)
tab situation familiale moto
res.ca <- MCA(type rouleur2[,2:6])
sup_moto <- gr_sum %>%
group by (kmMoto) %>%
 filter(kmMoto >= moyenne km an)
inf moto <- gr sum %>%
 group by (kmMoto) %>%
```



```
filter(kmMoto < moyenne km an)</pre>
sup_auto <- gr_sum %>%
group_by(auto) %>%
filter(auto >= moyenne_km_an)
inf_auto <- gr_sum %>%
 group by(auto) %>%
 filter(auto < moyenne_km_an)</pre>
View(sup auto)
View(inf auto)
#TODO: afficher la part de gros rouleurs en moto
♦ partir de ces diagrammes et calculs on d�duit le reste
#resum gros rouleurs <- data.frame("rows bdd" = dim(bdd)[1],</pre>
                                      "modalit� de s�paration" = "Moyenne fr: 17000
effectifs <- data.frame(stat=c("Total �tudi�","Gros rouleurs en moto","Petits
effectif=c(dim(bdd)[1],dim(sup moto)[1],dim(inf moto)[1],dim(sup auto)[1],dim(inf a
uto)[1]))
View(effectifs)
pourcentage gros rouleurs fr <- effectifs[-5,][-3,][-1,] %>%
mutate(pourcentage = round(effectif / dim(bdd)[1] * 100,2))
pourcentage petits rouleurs fr <- effectifs[-4,][-2,][-1,] %>%
mutate(pourcentage = round(effectif / dim(bdd)[1] * 100,2))
View(pourcentage gros rouleurs fr)
```



```
View(pourcentage petits rouleurs fr)
diag pourcentage GR fr <-
   ggplot(data=pourcentage_gros_rouleurs_fr, aes(x=stat, y=pourcentage,
=factor(stat))) +
 geom bar(stat="identity") +
 scale fill brewer(palette="Set1") +
 labs(fill="V�hicule",
     title="R@partition du nombre de gros rouleurs en fonction du v@hicule",
        caption="Figure 2: R♦partition du nombre de gros rouleurs en fonction du
r�hicule") +
 geom_text(aes(y = pourcentage / 2, label = pourcentage ), color = "white",
size=5,check overlap = TRUE)+
 theme(legend.position="none")
diag pourcentage GR fr
diag pourcentage PR fr <-
  ggplot(data=pourcentage_petits_rouleurs_fr, aes(x=stat, y=pourcentage, fill
=factor(stat))) +
 scale fill brewer(palette="Set1") +
 labs(fill="V�hicule",
     x=NULL,
     title="R\phipartition du nombre de petits rouleurs en fonction du v\phihicule",
       caption="Figure 2: R♦partition du nombre de petits rouleurs en fonction du
v�hicule") +
 geom_text(aes(y = pourcentage / 2, label = pourcentage ), color = "white",
size=5,check overlap = TRUE) +
 theme(legend.position="none")
diag pourcentage PR fr
```



## Annexe 3:

```
usage1 <- bdd %>%
usage2 <- bdd %>%
 select(usage="Q15 [2]")
usage3 <- bdd %>%
 select(usage="Q15 [3]")
usage4 <- bdd %>%
 select(usage="Q15 [4]")
usage5 <- bdd %>%
usage6 <- bdd %>%
 select(usage="Q15 [6]")
usagecor <- cbind(usage1,usage2,usage3,usage4,usage5,usage6)</pre>
to filter Usage <- function(usage){
 for (i in 1:dim) {
     if(j != 1 \&\& (usage[i,1] \&in\& c(1,5,6)) \&\& (usage[i,j] \&in\& c(1,5,6))){
     if(j != 2 && (usage[i,2] %in% c(1,5,6)) && (usage[i,j] %in% c(1,5,6))){
       usage[i,j] <- NA
     if(j != 3 && (usage[i,3] %in% c(1,5,6)) && (usage[i,j] %in% c(1,5,6))){
     if(j != 4 && (usage[i,4] %in% c(1,5,6)) && (usage[i,j] %in% c(1,5,6))){
```



```
if(j != 5 && (usage[i,5] %in% c(1,5,6)) && (usage[i,j] %in% c(1,5,6))){
      usage[i,j] <- NA
usagecor <- to filter Usage(usagecor)
#attribution des valeur corigé au different usage
usage1[,1] <- usagecor[,1]
usage2[,1] <- usagecor[,2]
usage3[,1] <- usagecor[,3]
usage4[,1] <- usagecor[,4]
usage5[,1] <- usagecor[,5]
usage6[,1] <- usagecor[,6]
#correspond au nombre d'apparition de chaque type d'usage
usageVoiture <- rbind(usage1,usage2) %>% rbind(usage3) %>% rbind(usage4) %>%
rbind(usage5) %>% rbind(usage6) %>%
      group by(usage) %>%
View(usageVoiture)
usageVoiture[1,2] <- usageVoiture[1,2] + usageVoiture[5,2] + usageVoiture[6,2]
usage1 <- bdd %>%
select(usage = "Usage 1")
usage2 <- bdd %>%
usage3 <- bdd %>%
usage4 <- bdd %>%
usage5 <- bdd %>%
```



```
#correspond au nombre d'apparition de chaque type d'usage
usageMoto <- rbind(usage1,usage2) %>% rbind(usage3) %>% rbind(usage4)
                                                                                 응>응
rbind(usage5) %>%
arrange(usage) %>%
group_by(usage) %>%
View(usageMoto)
#-- AFC Usage par véhicule --#
usageMoto1 <- usage1 %>%
group by(usage) %>%
usageMoto1[4,2] <- 0
usageMoto2 <- usage2 %>%
group by (usage) %>%
usageMoto2[4,2] <- 0
usageMoto3 <- usage3 %>%
arrange(usage) %>%
group by (usage) %>%
usageMoto3[4,2] <- 0
usageMoto4 <- usage4 %>%
group by (usage) %>%
usageMoto4[4,2] <- 0
usageMoto5 <- usage5 %>%
```



```
arrange(usage) %>%
 group_by(usage) %>%
usageMoto5[4,2] <- 0
#probleme avec les valeur manquante
usageMoto5[2:4,2] <- 0
AFC usage <- usageVoiture[1:4,2]
AFC usage[,2] <- usageMoto1[,2]
AFC usage[,3] <- usageMoto2[,2]
AFC_usage[,4] <- usageMoto3[,2]
AFC usage[,5] <- usageMoto4[,2]
AFC_usage[,6] <- usageMoto5[,2]
#on enlève les course, on pourra essayer en les rajoutant
AFC_usage <- AFC_usage[1:3,]
rownames(AFC usage) <- c("Loisir","Domicile-travail", "Travail")</pre>
dt <- as.table(as.matrix (AFC usage))</pre>
View(dt)
balloonplot(t (dt), main = "AFC usage", xlab = "", ylab = "",
chisq <- chisq.test (AFC usage)</pre>
res AFC <- CA (AFC usage, graph = TRUE)
#analyse des valeur propre
eig.val <- get_eigenvalue (res_AFC)
fviz contrib(res_AFC, choice = "col", axes = 1, top = 10)
```



```
fviz_contrib(res_AFC, choice = "col", axes = 2, top = 10)
fviz contrib(res AFC, choice = "row", axes = 1, top = 10)
fviz contrib(res AFC, choice = "row", axes = 2, top = 10)
# repel = TRUE pour éviter le chevauchement de texte
fviz ca biplot (res AFC)
ggplot(res AFC)
usage <- bdd %>%
                                                                             [1]",
usageVoiture2="Q15 [2]",
                 usageVoiture6="Q15 [6]", usageM1="Usage 1", kmM1="Nb km 1",
usageM2="...55",
        kmM2="...56", usageM3="...66", kmM3="...67", usageM4="...77", kmM4="...78",
       usageM5="...89", kmM5="...90")
#fonctions pour transformer les donnees en qq chose de lisible
to readable auto <- function(code){
if (is.na(code))
```



```
to_readable_auto_vector <- Vectorize(to_readable_auto, vectorize.args = "code")
to_readable_moto <- function(code){
 if (is.na(code))
to readable moto vector <- Vectorize(to readable moto, vectorize.args = "code")
usage readable <- usage %>%
 mutate(usageVoiture5 = to readable auto vector(usageVoiture5)) %>%
 mutate(usageM1 = to readable moto vector(usageM1)) %>%
 mutate(usageM2 = to readable moto vector(usageM2)) %>%
 mutate(usageM3 = to readable moto vector(usageM3)) %>%
 mutate(usageM4 = to readable moto vector(usageM4)) %>%
 mutate(usageM5 = to readable moto vector(usageM5))
View(usage)
View(usage readable)
```



```
usageVoiturePLot <- usageVoiture[1:3,2]
usageVoiturePLot <- mutate(usageVoiturePLot ,prop = round(Voiture</pre>
sum(usageVoiturePLot$Voiture) *100,2))%>%
                  mutate(ypos = cumsum(prop) - 0.5*prop)
dt <- data.frame(
 ypos = usageVoiturePLot[,3]
diag_intro <- ggplot(dt, aes(x = "", y = prop, fill = factor(type))) +</pre>
 labs(fill="Type d'usage",
     caption="Figure 1: Diagramme R, répartition des usages des autos") +
 geom text(aes(y = ypos, label = prop), color = "white", size=5,check overlap =
 scale fill brewer(palette="Dark2") +
diag intro
usageMotoPLot <- usageMoto[1:3,2]
usageMotoPLot <- mutate(usageMotoPLot ,prop = round(Nombre_de_personnes
sum(usageMotoPLot$Nombre de personnes) *100,2))%>%
 mutate(ypos = cumsum(prop) - 0.5*prop )
dtm <- data.frame(
```



```
diag_intro_moto <- ggplot(dtm, aes(x = "", y = prop, fill = factor(type))) +</pre>
 geom bar(width = 1, stat = "identity") +
 labs(fill="Type d'usage",
     x=NULL,
      caption="Figure 2: Diagramme R, répartition des usages des motos") +
 geom text(aes(y = ypos, label = prop), color = "white", size=5,check overlap =
 scale fill brewer(palette="Dark2") +
diag intro moto
usagePLot <- usageMoto[1:3,2] + usageVoiture[1:3,2]</pre>
usagePLot
            <- mutate(usagePLot
                                                    round (Nombre de personnes
sum(usagePLot$Nombre de personnes) *100,2))%>%
mutate(ypos = cumsum(prop) - 0.5*prop )
usagePLot
dtall <- data.frame(</pre>
prop = usagePLot[,2],
 ypos = usagePLot[,3]
diag_intro_moto <- ggplot(dtall, aes(x = "", y = prop, fill = factor(type))) +
 labs(fill="Type d'usage",
     x=NULL,
      caption="Figure 2: Diagramme R, répartition des usages pour les motos et les
 geom text(aes(y = ypos, label = prop), color = "white", size=5,check overlap =
 scale fill brewer(palette="Dark2") +
 coord polar("y", start=0)
```



```
diag_intro_moto
```

## Annexe 4: Server Shiny App

```
library(shiny)
library("readxl")
library(ggplot2)
library(dplyr)
bdd auto
read excel("C:/Users/alexa/Documents/R/dataScience/Data/bdd auto-modif.xlsx")
bdd 2 roue
read excel("C:/Users/alexa/Documents/R/dataScience/Data/bdd_2_roue.xls")
colnames(bdd 2 roue)[colnames(bdd 2 roue)=="...1"] <- "Identifiant"</pre>
colnames(bdd 2 roue)[colnames(bdd 2 roue)=="...2"] <- "Date"
bdd <- merge(bdd_auto, bdd_2_roue, by="Identifiant")</pre>
gros rouleurs <- bdd %>%
moto4="...78", kmAuto="Q17 [1]", Nombre personnes foyer = "Nombre personnes au
gros rouleurs$moto1 <- as.numeric(as.character(gros rouleurs$moto1))
gros_rouleurs$moto2 <- as.numeric(as.character(gros_rouleurs$moto2))</pre>
gros rouleurs$moto3 <- as.numeric(as.character(gros rouleurs$moto3))
gros_rouleurs$moto4 <- as.numeric(as.character(gros_rouleurs$moto4))</pre>
gros rouleurs$Nombre enfants
as.numeric(as.character(gros rouleurs$Nombre enfants))
```



```
gros_rouleurs[is.na(gros_rouleurs)] <- 0</pre>
gr_sum <- gros_rouleurs %>%
  arrange(desc(kmMoto))
gr_sum_total <- gr_sum %>%
  mutate(kmTotaux = kmMoto + kmAuto)
isGrosRouleur_moto <- function(km){
  if (km <= moyenne_km_an)</pre>
  if (km > moyenne_km_an)
isGrosRouleur_moto_vector <- Vectorize(isGrosRouleur moto, vectorize.args = "km")
isGrosRouleur auto <- function(km){
  if (km <= moyenne_km_an)</pre>
  if (km > moyenne_km_an)
isGrosRouleur auto vector <- Vectorize(isGrosRouleur auto, vectorize.args = "km")
isAssure <- function(num){
isAssure vector <- Vectorize(isAssure, vectorize.args = "num")</pre>
situation familiale <- function(num){</pre>
```



```
situation_familiale_vector <- Vectorize(situation_familiale, vectorize.args
is en couple <- function(situation){
is_en_couple_vector <- Vectorize(is_en_couple, vectorize.args = "situation")
hasEnfants <- function(situation){
hasEnfants vector <- Vectorize(hasEnfants, vectorize.args = "situation")
type rouleur <- gr sum total %>%
  mutate(gros rouleur moto = isGrosRouleur moto vector(kmMoto)) %>%
  mutate(situation familiale = situation familiale vector(Situation familiale))%>%
```



```
mutate(en couple = is en couple vector(situation familiale)) %>%
select(Identifiant,gros_rouleur_moto,gros_rouleur_auto,en_couple,Nombre_enfants,kmT
otaux, kmAuto, kmMoto)
situation_couple <- type_rouleur %>%
  group by (en couple) %>%
   summarise(moy km moto = round(mean(kmAuto, na.rm=TRUE),2),
situation famille <- type rouleur %>%
  group_by(Nombre_enfants) %>%
   summarise(moy km moto = round(mean(kmAuto, na.rm=TRUE),2),
View(situation famille)
shinyServer(function(input, output) {
   output$plot1 <- renderPlot({</pre>
       moyenne_km_an <- input$separation</pre>
           group by(kmMoto) %>%
           filter(kmMoto >= moyenne km an)
           group_by(kmMoto) %>%
           filter(kmMoto < moyenne km an)</pre>
```



```
group by(kmAuto) %>%
           filter(kmAuto >= moyenne_km_an)
           group_by(kmAuto) %>%
           filter(kmAuto < moyenne km an)</pre>
               effectifs <- data.frame(stat=c("Total etudie", "Gros rouleurs en
moto","Petits rouleurs en moto","Gros rouleurs en auto","Petits rouleurs en auto"),
effectif=c(dim(bdd)[1],dim(sup moto)[1],dim(inf moto)[1],dim(sup auto)[1],dim(inf a
uto)[1]))
           mutate(pourcentage = round(effectif / dim(bdd)[1] * 100,2))
         ggplot(data=pourcentage gros rouleurs fr, aes(x=stat, y=pourcentage, fill
=factor(stat))) +
           scale fill brewer(palette="Set1") +
"white", size=5,check_overlap = TRUE)+
           theme(legend.position="none")
  output$plot2 <- renderPlot({</pre>
         ggplot(data=situation couple, aes string(x="en couple", y=kmEtudie, fill =
           scale fill brewer(palette="Set2") +
           labs(fill="situation",
                y="Km",
                       title="Moyenne de km parcourus en fonction de la situation
```





## Annexe 5: UI Shiny App

```
library(shiny)
shinyUI(
   fluidPage(
           tabsetPanel(
                         wellPanel(
des types de rouleurs:",
                             tabPanel ("Situation Maritale",
```

